



# VUES LOGIQUE ET GRAPHE DES FAITS ET DES REQUÊTES CONJONCTIVES

HAI933I

# Rappels du cours précédent

# FACTBASE

---

**Vocabulary** :  $(\mathcal{P}, C)$  where  $\mathcal{P}$  is a finite set of predicates  
 $C$  is a possibly infinite set of constants

[**Arity** of a predicate = its number of arguments]

$\mathcal{P} = \{ \text{Prof}/1, \text{PHS}/1, \text{involvedIn}/2, \dots \}$

$C = \{ \text{Bob}, \#1, 456, \dots \}$

**Fact** : a **ground atom**  $p(e_1 \dots e_k)$  with  $p \in \mathcal{P}$  and  $e_i \in C$  [ground = no variables]

$\text{involvedIn}(\text{Bob}, \#1)$

**Factbase** : usually a set of **ground atoms** on the vocabulary

$F = \{ \text{Prof}(\text{Bob}), \text{PHS}(\#1), \text{involvedIn}(\text{Bob}, \#1) \}$

logically seen as the **conjunction** of these atoms

$\text{Prof}(\text{Bob}) \wedge \text{PHS}(\#1) \wedge \text{involvedIn}(\text{Bob}, \#1)$

# FACTBASES CAN BE EXTENDED TO UNKNOWN VALUES

An unknown value is logically seen as an **existentially quantified variable**

Then a **factbase** is logically seen as the **existential closure of the conjunction of its atoms**

Relational database

Movie		Actor		Play	
m_id		a_id		m_id	a_id
m1		a		a	m1
m2	...	b	...	a	m2
?x	...	c	...	c	?x

Factbase

```
{ movie(m1), movie(m2), movie(x),  
  actor(a), actor(b), actor(c), play(a,m1),  
  play(a,m2), play(c,x) }
```

Logical formula assigned to the factbase

```
 $\exists x ( \text{movie}(m1) \wedge \text{movie}(m2) \wedge \text{movie}(x) \wedge$   
 $\text{actor}(a) \wedge \text{actor}(b) \wedge \text{actor}(c)$   
 $\text{play}(a,m1) \wedge \text{play}(a,m2) \wedge \text{play}(c,x) )$ 
```

# CONJUNCTIVE QUERIES (CQ)

---

$q(x) = \exists y (\text{movie}(y) \wedge \text{play}(x, y))$  « *find all those who play in a movie* »

$q() = \exists y (\text{movie}(y) \wedge \text{play}(b, y))$  « *does b play in a movie ?* » (*b is a constant*)

A **CQ** is an **existentially quantified conjunction of atoms**

The **free variables** are the **answer variables**

If **closed** formula: **Boolean CQ**

Simplified notation

$q(x) = \{ \text{movie}(y), \text{play}(x, y) \}$

Rule notation

$\text{ans}(x) \leftarrow \text{movie}(y), \text{play}(x, y)$

classical **Datalog** notation

$\text{movie}(y), \text{play}(x, y) \rightarrow \text{ans}(x)$

alternative notation

Basic SQL queries (on relational databases)

SELECT ... FROM ... WHERE *<equalities: restrictions and joins>*

Basic SPARQL (on RDF triples)

SELECT ... WHERE *<basic graph pattern>*

# ANSWERS TO A CONJUNCTIVE QUERY

- The answer to a BCQ  $Q$  in  $F$  is **yes** if  $F \models Q$   
 $yes = ()$
- A tuple  $(a_1, \dots, a_k)$  of constants is an answer to  $Q(x_1, \dots, x_k)$  with respect to  $F$  if  $F \models Q[a_1, \dots, a_k]$ , where  $Q[a_1, \dots, a_k]$  is obtained from  $Q(x_1, \dots, x_k)$  by replacing each  $x_i$  by  $a_i$ .
- Let  $F$  and  $Q$  be seen as sets of atoms. A homomorphism  $h$  from  $Q$  to  $F$  is a mapping from  $variables(Q)$  to  $terms(F)$  such that  $h(Q) \subseteq F$

$F \models Q()$  iff  $Q$  can be mapped by homomorphism to  $F$

$(a_1, \dots, a_k)$  is an answer to  $Q(x_1, \dots, x_k)$  on  $F$  iff there is a homomorphism from  $Q$  to  $F$  that maps each  $x_i$  to  $a_i$

## FRAGMENT EXISTENTIEL CONJONCTIF POSITIF : $\text{FOL}(\exists, \wedge)$

Formules construites avec le quantificateur existentiel ( $\exists$ ) et la conjonction ( $\wedge$ )

- Forme normalisée (« prénexe ») :

$\exists x_1 \dots \exists x_n (A_1 \wedge \dots \wedge A_p)$  où les  $A_i$  sont des atomes  
et chaque  $x_j$  apparaît dans un  $A_i$

- Permettent de représenter des bases de faits (et bases de données relationnelles) et des requêtes conjonctives
- Pour des formules closes :

$f1 \models f2$  ssi il existe un homomorphisme de  $f1$  dans  $f2$


Dans ce cours :

- Vision « graphe » de ces formules ( $\Rightarrow$  homomorphisme de graphe)
- Notion de minimalité : peut-on supprimer des atomes en gardant une formule équivalente ? Deux formules équivalentes sont-elles « identiques » ?

- On note  $G = (V, E)$  un **graphe orienté** où  $V$  est l'ensemble des sommets (*vertices*) et  $E$  est l'ensemble des arcs (*edges*)
- Un ensemble d'atomes avec **un seul prédicat binaire** et **sans constantes** peut être vu comme un graphe orienté

$\{ p(x,y), p(y,z), p(z,x), p(y,y) \}$

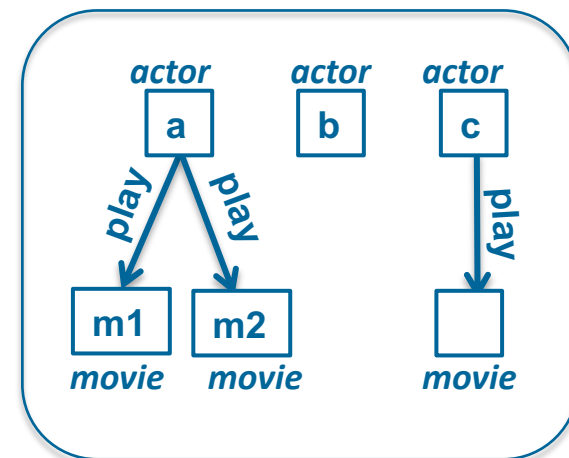
bijections : termes (variables ici)  $\rightarrow V$   
 atomes  $\rightarrow E$



(et réciproquement)

- On **étiquette** : les **arcs** si on a plusieurs prédicats binaires  
 les **sommets** si on a des constantes
- On peut ajouter un 2<sup>ème</sup> type d'étiquette pour représenter les prédicats unaires

movie(m1), movie(m2), movie(x),  
 actor(a), actor(b), actor(c),  
 play(a,m1), play(a,m2), play(c,x)




Et si on a des prédicats  
 d'arité supérieure à 2 ?



# ENSEMBLE D'ATOMES ENCODÉ PAR UN GRAPHE

- À un ensemble d'atomes, on associe naturellement un **hypergraphe « orienté »**.  
La notion d'**hyperarc** généralise la notion d'arc : n-uplet ( $n > 0$ ) de sommets
- Il est pratique de considérer le **graphe d'incidence associé** à l'hypergraphe.  
C'est un **multi-graphe biparti non-orienté**
  - « biparti » : l'ensemble des sommets est partitionné en 2 classes, tel qu'il n'y a aucun arc entre 2 sommets de la même classe
  - « multi-graphe » : il peut y avoir plusieurs arêtes entre deux sommets



- 1 **sommet** par **terme**  
étiqueté par le terme si c'est une constante
- 1 **sommet** par **atome**  
étiqueté par le prédicat de l'atome
- les **arêtes** lient chaque sommet atome aux sommets qui représentent ses arguments
- les arêtes incidentes à un sommet atome sont totalement ordonnées (ce qu'on peut représenter par une numérotation)

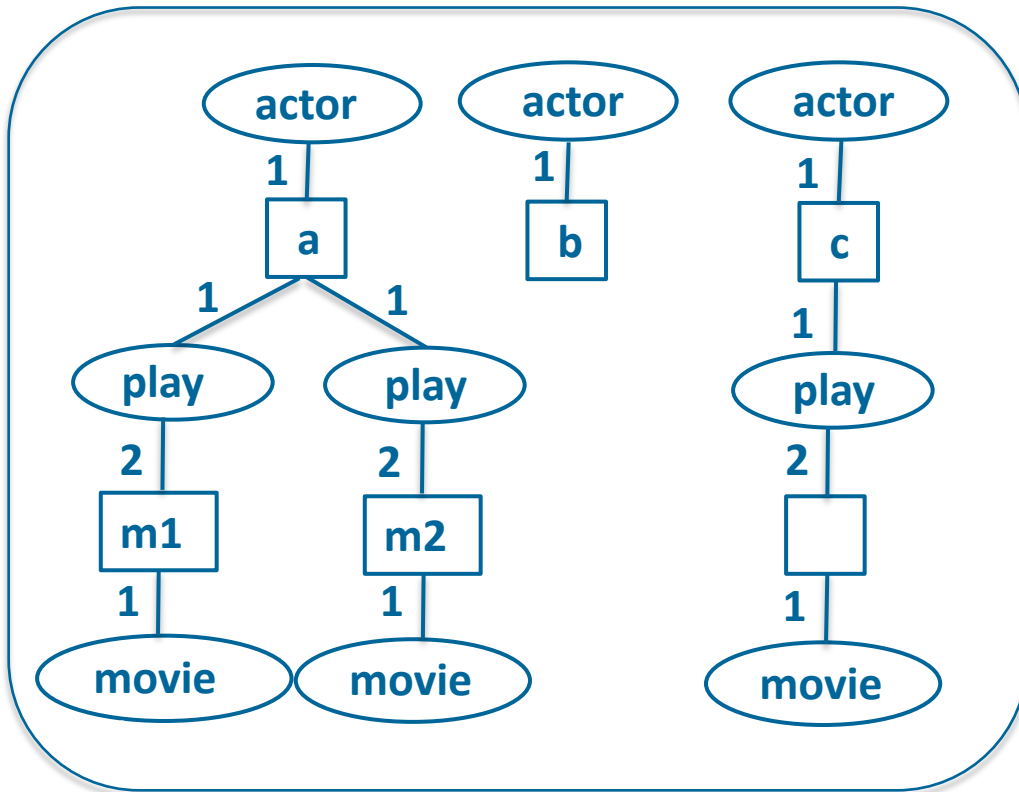
## PLUS PRÉCISÉMENT :

---

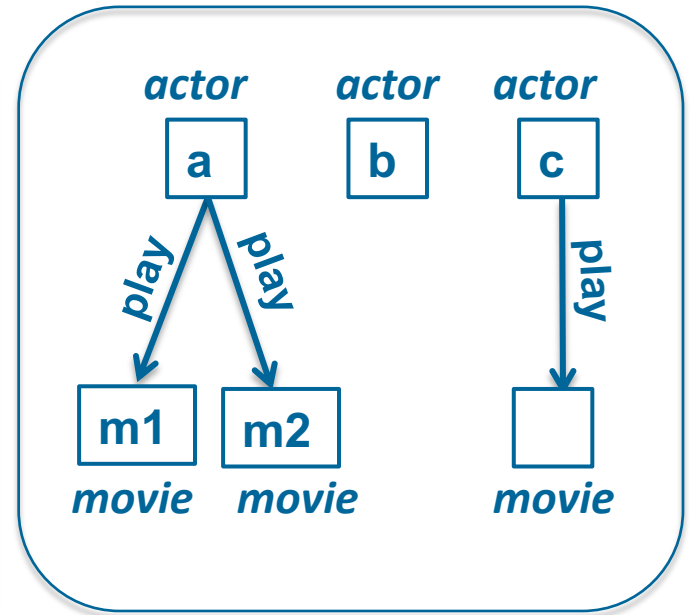
À un ensemble d'atomes  $F$ , on associe un (multi-)graphe biparti  $(V_T, V_A, E, \text{label})$  tel que :

- $V_T$  : ensemble des sommets termes  
(on a une bijection  $b_T$  de l'ensemble des termes de  $F$  vers  $V_T$ )
- $V_A$  : ensemble des sommets atomes  
(on a une bijection  $b_A$  de l'ensemble des atomes de  $F$  vers  $V_A$ )
- $E$  : multi-ensemble des arêtes : pour chaque atome  $A = p(t_1, \dots, t_k)$  de  $F$ ,  
on a  $k$  arêtes entre  $b_A(A)$  et chacun des  $b_T(t_i)$
- **label** : fonction d'étiquetage qui vérifie :
  - tout **sommet terme**  $b_T(t)$  est étiqueté par  $t$  si  $t$  est une constante, sinon il n'est pas étiqueté
  - tout **sommet atome**  $b_A(A)$  avec  $A = p(t_1, \dots, t_k)$  est étiqueté par  $p$  et chaque arête  $(b_A(A), b_T(t_i))$  est étiquetée par  $i$

movie(m1), movie(m2), actor(a), actor(b), actor(c),  
play(a,m1), play(a,m2), movie(x), play(c,x)



graphe biparti associé à la vision « hypergraphe »



graphe plus simple  
(car prédicats d'arité  $\leq 2$ )

# ISOMORPHISM OF SETS OF ATOMS / GRAPHS

- Let  $f$  and  $g$  be sets of atoms

**Isomorphism**  $h$  from  $f$  to  $g$ : **bijjective** mapping from  $var(f)$  to  $var(g)$   
such that  $h(f) = g$

When  $f$  and  $g$  are isomorphic :

we also say that  $f$  and  $g$  are "equal up to a bijective variable renaming"

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs

**Isomorphism**  $h$  from  $G_1$  to  $G_2$ : **bijjective** mapping from  $V_1$  to  $V_2$   
such that for all vertices  $u,v$  in  $V_1$ ,  
 $(u,v)$  is in  $E_1$  if and only if  $(h(u),h(v))$  is in  $E_2$

If the graphs are labeled:

$label(u) = label(h(u))$  for all  $u$  in  $V_1$





$label((u,v)) = label(h(u),h(v))$  for all  $(u,v)$  in  $E_1$

Les transformations précédentes assurent que deux ensembles d'atomes sont transformés en des graphes isomorphes **ssi** ils sont isomorphes


# GRAPH HOMOMORPHISMS (1)

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs.

**Homomorphism**  $h$  from  $G_1$  to  $G_2$ : mapping from  $V_1$  to  $V_2$  s. t.  
for every edge  $(u,v)$  in  $E_1$ ,  $(h(u),h(v))$  is in  $E_2$



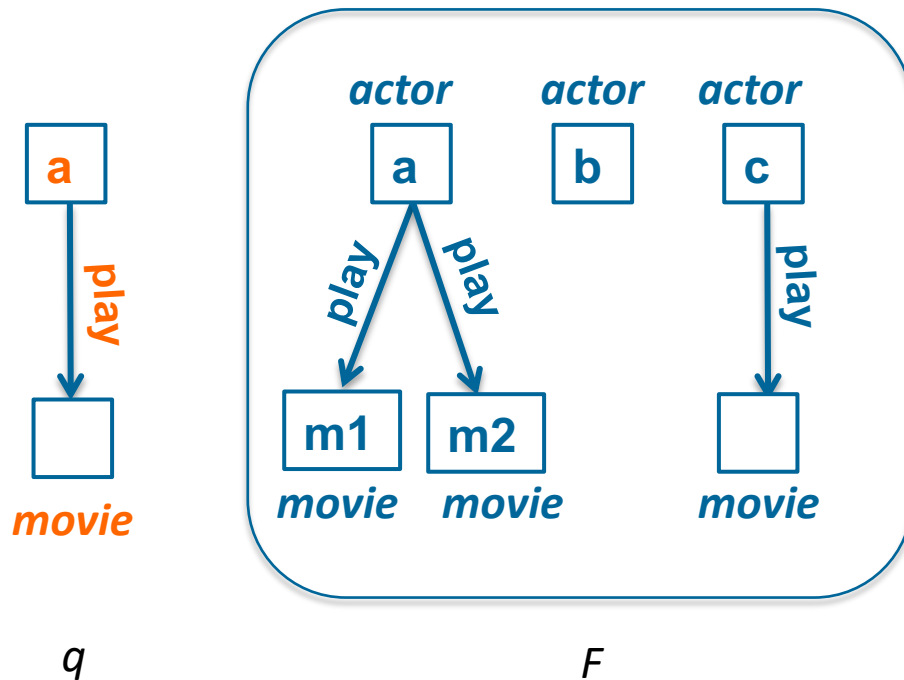
*Find the homomorphisms between these graphs*



Here,  $F \geq G$  means  
 «  $F$  maps to  $G$  by homomorphism »

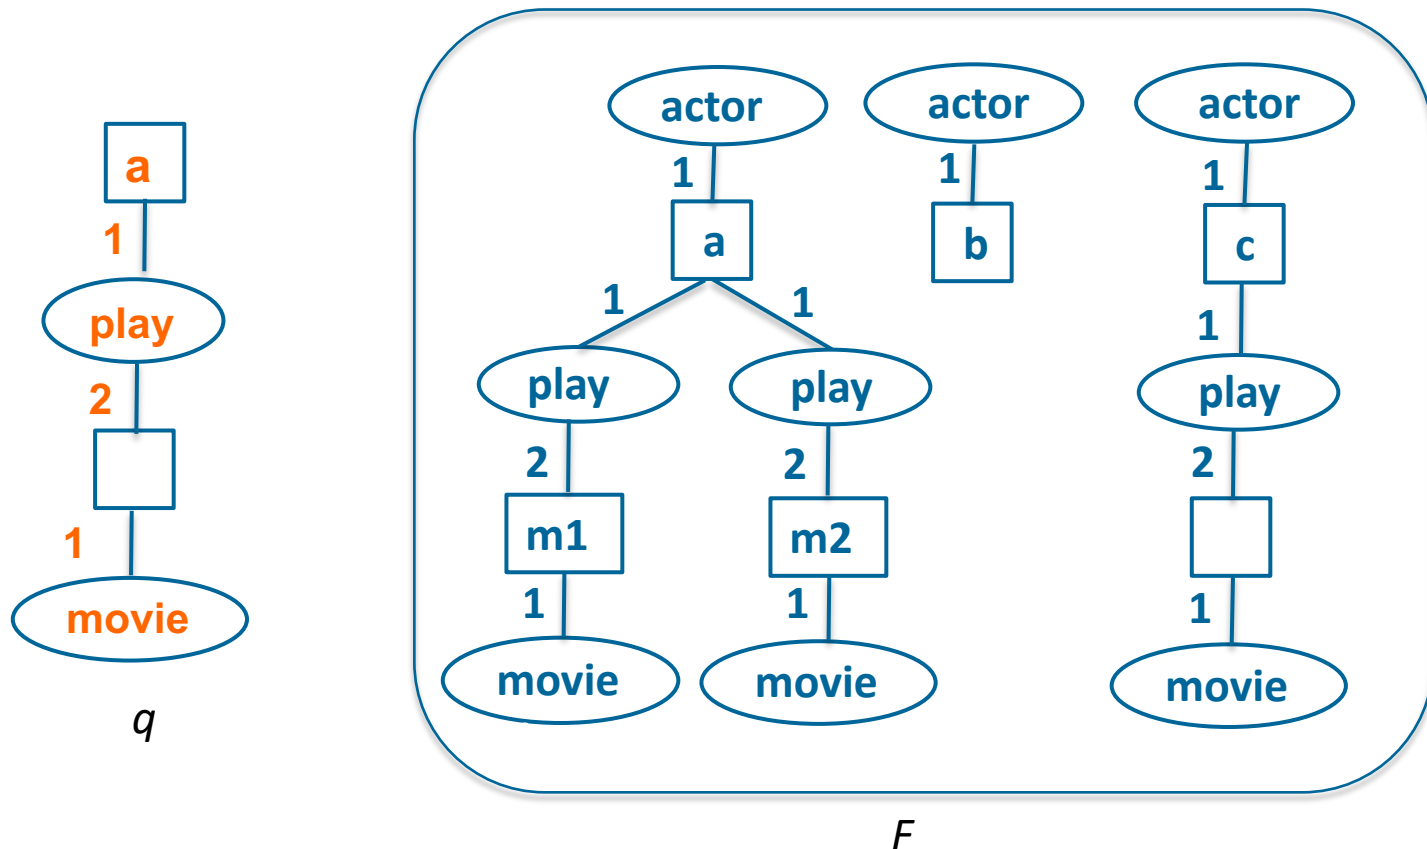
# GRAPH HOMOMORPHISMS (2)

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs.  
**Homomorphism**  $h$  from  $G_1$  to  $G_2$ : mapping from  $V_1$  to  $V_2$  s. t.  
for every edge  $(u,v)$  in  $E_1$ ,  $(h(u),h(v))$  is in  $E_2$
- If there are labels: they have to be “kept” as well



# GRAPH HOMOMORPHISMS (3)

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs.  
**Homomorphism**  $h$  from  $G_1$  to  $G_2$ : mapping from  $V_1$  to  $V_2$  s. t.  
for every edge  $(u,v)$  in  $E_1$ ,  $(h(u),h(v))$  is in  $E_2$
- If there are labels: they have to be “kept” as well






# EXERCICE

---

Nous avons vu que nous pouvions encoder tout **ensemble d'atomes** par un **multi-graphe biparti**.

- Définir la notion d'homomorphisme naturellement associée avec ces graphes.
- Montrer que : pour tous ensembles d'atomes  $F1$  et  $F2$ ,  
il existe un homomorphisme de  $F1$  vers  $F2$  si et seulement si  
il existe un homomorphisme (de graphes) de *graphe*( $F1$ ) vers *graphe*( $F2$ ).




$f$  maps to  $g$  by homomorphism

$g$  is « more specific » than  $f$

$\geq$  is not an order but a **preorder**  
(a reflexive and transitive relation)

# BACK TO ISOMORPHISM


- Let  $f$  and  $g$  in  $\text{FOL}(\exists, \wedge)$  seen as sets of atoms
- Isomorphism  $h$  from  $f$  to  $g$ : bijective mapping from  $\text{var}(f)$  to  $\text{var}(g)$  such that  $h(f) = g$
- Equivalent definition of isomorphism: homomorphism  $h$  from  $f$  to  $g$  such that  $h^{-1}$  is a homomorphism from  $g$  to  $f$



One may have  $f \geq g$  and  $g \geq f$ , but  $f$  and  $g$  are not isomorphic

# EQUIVALENCE / CORE

- If  $f \geq g$  and  $g \geq f$ , they are called (homomorphically) **equivalent**
- A **core** is a set of atoms that is not equivalent to any of its strict subsets
- Given  $f$  a set of atoms, the **core of  $f$**  is a minimal subset of  $f$  equivalent to  $f$ . It may happen that  $f$  has several cores, but they are **all isomorphic**. Hence, we can say « the » core of  $f$ .
- If  $f$  and  $g$  are **equivalent**, the core of  $f$  is **isomorphic** to the core of  $g$ .



Exercice : give an algorithmic scheme to **compute the core** of an atom set.

# CONCLUSION

---

- Le **fragment logique existentiel conjonctif** est fortement lié aux **graphes** / hypergraphes  
(donc aux modèles de données graphes, comme RDF)
- Les notions d'homomorphisme et de core sont fondamentales pour de nombreux problèmes sur les bases de faits et les requêtes

Par exemple : **optimisation de requêtes** conjonctives

- Déterminer si deux requêtes sont équivalentes
  - but : exécuter la plus simple pour le SGBD
- Minimiser une requête : supprimer toutes ses redondances
  - but : accélérer l'évaluation de la requête

[ On parle de problèmes d'optimisation « **statique** » de requêtes, au sens où ils sont indépendants d'une base de données (ou base de faits) particulière ]

# EXERCICE 1 : INCLUSION DE REQUÊTES

---

Etant données deux requêtes conjonctives booléennes,  $Q1$  et  $Q2$ , on dit que  $Q1$  est **include** dans  $Q2$  (notation  $Q1 \sqsubseteq Q2$ ) si l'ensemble des bases de faits qui répondent oui à  $Q1$  est inclus dans l'ensemble des bases de faits qui répondent oui à  $Q2$ .



Utiliser les notions vues dans ce cours pour prouver que :

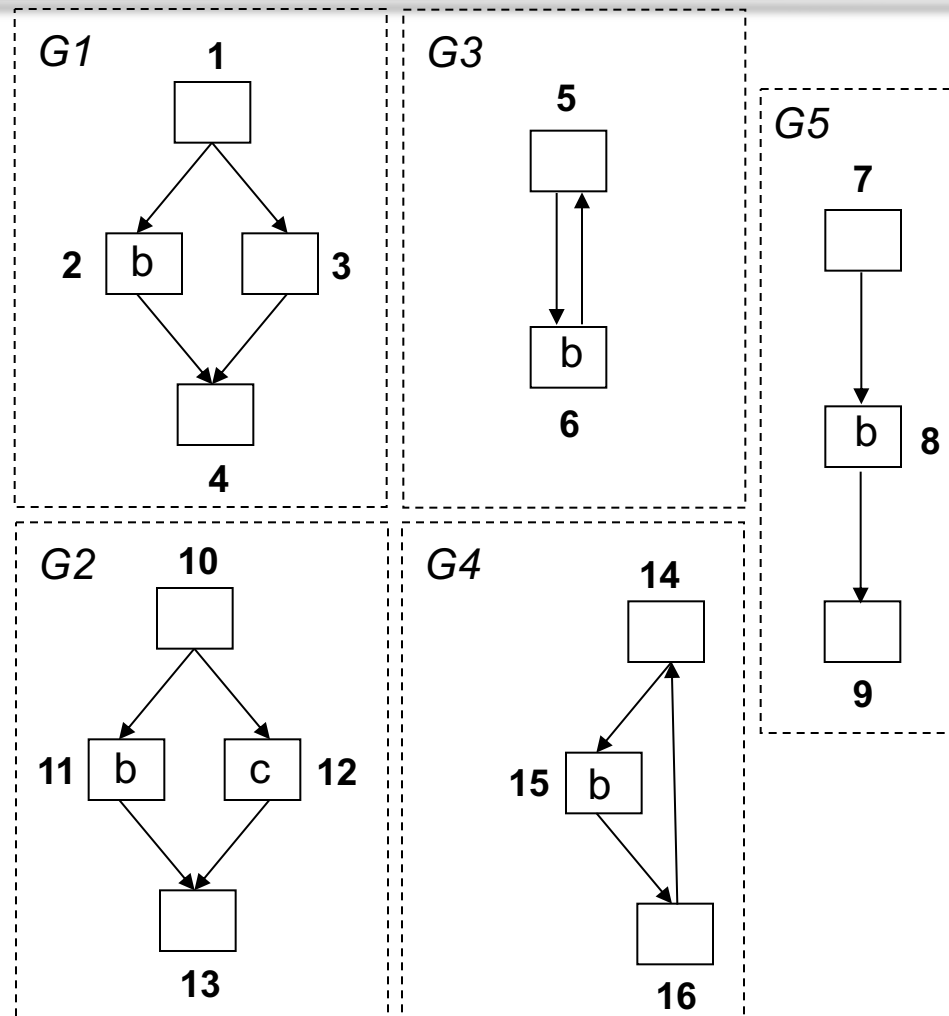
$$Q1 \sqsubseteq Q2$$

ssi

il existe un **homomorphisme de  $Q2$  dans  $Q1$**

**Question subsidiaire** : pour des requêtes quelconques,  $Q1$  est incluse dans  $Q2$  si pour toute base de faits, l'ensemble des réponses à  $Q1$  est inclus dans l'ensemble des réponses à  $Q2$ . Comment étendre le résultat précédent ?

## EXERCICE 2 : HOMOMORPHISMES



1. En supposant qu'on n'ait que le prédicat binaire  $p$ , quelles sont les **formules logiques** associées à ces graphes ?
2. Les classer par **homomorphisme** (en utilisant la vue logique ou graphe)